

[SDE IV] 倒向随机微分方程与非线性Feynman–Kac 公式

Anqiao Ouyang, Xuecheng Liu

May 27, 2026

1 引言

本专栏前三篇文章主要围绕前向随机微分方程展开。在[SDE I] 我们构造了布朗运动，并铺设了相关的测度论基础；在[SDE II] 我们发展了Itô 积分以及随机分析的链式法则；在[SDE III] 我们证明了前向SDE 的解的存在唯一性，并通过**Feynman–Kac** 公式跨入到PDE 的世界：对线性抛物型问题

$$\partial_t u + \mathcal{L}u = 0, \quad u(T, x) = g(x),$$

其中 $\mathcal{L}$ 是 X 的无穷小生成元，解具有概率表示

$$u(t, x) = \mathbb{E}[g(X_T) \mid X_t = x].$$

一个自然的问题是：如果在PDE 中加入一个非线性源项，会发生什么？

$$\partial_t u + \mathcal{L}u + f(t, x, u, \sigma^\top \nabla u) = 0, \quad u(T, x) = g(x).$$

线性Feynman–Kac 中的期望在固定时刻 T 取，被积函数里并不含 u 或 ∇u 。要把它纳入，需要一个能让信息沿时间反向传递的表示，把 X 在整个 $[t, T]$ 上的路径都纳入条件。完成这项工作的对象正是**倒向随机微分方程**（backward stochastic differential equation, BSDE）。

形式上，BSDE 是一条从终端条件 $Y_T = \xi$ 倒回0 时刻的“SDE”：

$$-dY_t = f(t, Y_t, Z_t) dt - Z_t dB_t, \quad Y_T = \xi.$$

未知量是一对过程 (Y_t, Z_t) ： Y 是实值过程， Z 是针对布朗运动的被积函数。我们在§2 会看到， Z 并非额外的数据选择，而是适应性条件（通过鞅表示定理）强加给我们的。当 $\xi = g(X_T)$ 、且 f 以Markov 方式依赖 (t, X_t, Y_t, Z_t) 时，BSDE 恰好求解上述半线性PDE，并有对应关系

$$Y_t = u(t, X_t), \quad Z_t = \sigma^\top(t, X_t) \nabla u(t, X_t).$$

这就是Pardoux 与Peng 的**非线性Feynman–Kac** 公式。

该理论由Pardoux 与Peng 于1990 年提出[1]，如今已深植于随机控制、数理金融，以及近年的深度学习PDE 求解器中。本文将：

- 精确定义BSDE，并说明为什么 (Y, Z) 这一对才是正确的未知量（§2）；
- 在Lipschitz 条件下证明Pardoux–Peng 的存在唯一性定理（§3）；
- 建立比较定理，并观察它如何反映定价的无套利结构（§4）；
- 为Markov 型BSDE 证明非线性Feynman–Kac 公式，与[SDE III] 中的线性版本并列对比（§5）；
- 将这套机制应用于随机最优控制（HJB），并概述Deep BSDE 数值方法（§6）；
- 以前向倒向耦合、平均场BSDE、反射型BSDE 与粗糙路径收尾（§7）。

标准记号。 我们在带流的概率空间 $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{0 \leq t \leq T}, \mathbb{P})$ 上工作, 其上有 d 维布朗运动 $B = (B_t)_{0 \leq t \leq T}$, $(\mathcal{F}_t)$ 为 B 的扩充流, 固定时间视域 $T > 0$ 。向量按列排列, $\sigma^\top$ 表示矩阵转置, $|\cdot|$ 是欧氏范数。“适应的”指 $(\mathcal{F}_t)$ -适应, “可预测的”指 $(\mathcal{F}_t)$ -可预测。 K 为一般性常数, 其数值可能逐行变动。

2 BSDE 的定义与 Z 的角色

2.1 为什么需要一对?

设想我们以最朴素的方式定义倒向SDE: 取终端条件 $\xi \in L^2(\mathcal{F}_T)$ 和驱动函数 $f(t, y)$, 寻找 $(\mathcal{F}_t)$ -适应的过程 Y 满足

$$Y_T = \xi, \quad -dY_t = f(t, Y_t) dt.$$

这只是一个逐轨道从 T 倒推的ODE。问题出在适应性: $Y_T = \xi$ 是 $\mathcal{F}_T$ -可测的, 因此由ODE从 T 倒推回去的 Y_t 会继承 ξ 的所有信息, 这在任何更早的时刻 $t < T$ 都违反 $\mathcal{F}_t$ -可测性。换句话说, 知道 Y_t 就能预测 ξ 。

补救方法是允许一个**鞅修正项**。根据鞅表示定理 (如[5], Ch. V), 每个满足 $M_0 = \mathbb{E}[\xi]$ 的平方可积布朗鞅 M 都存在唯一的可预测被积函数 $Z \in \mathcal{H}^2$ 使得

$$M_t = M_0 + \int_0^t Z_s dB_s.$$

取 $M_t := \mathbb{E}[\xi | \mathcal{F}_t]$, 就得到那个“承载”截至时刻 t 为止有关 ξ 之信息的 Z 。BSDE就是把确定性驱动 f 与这个布朗修正项 $Z dB$ 结合起来的积分等式。

定义2.1 (BSDE的解). 设 $\xi \in L^2(\mathcal{F}_T; \mathbb{R})$, $f : [0, T] \times \Omega \times \mathbb{R} \times \mathbb{R}^d \rightarrow \mathbb{R}$ 循序可测。称一对过程 (Y, Z) (其中 Y 连续、实值、 $(\mathcal{F}_t)$ -适应, Z 为 $(\mathcal{F}_t)$ -可预测且取值于 $\mathbb{R}^d$) 为BSDE (ξ, f) 的解, 若

$$Y_t = \xi + \int_t^T f(s, Y_s, Z_s) ds - \int_t^T Z_s dB_s, \quad t \in [0, T], \quad (1)$$

$\mathbb{P}$ -a.s. 成立, 且

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} |Y_t|^2 \right] < \infty, \quad \mathbb{E} \int_0^T |Z_s|^2 ds < \infty.$$

我们给解空间命名:

$$\mathcal{S}^2 := \left\{ Y \text{ 适应、连续} : \|Y\|_{\mathcal{S}^2}^2 := \mathbb{E} \left[\sup_t |Y_t|^2 \right] < \infty \right\},$$

$$\mathcal{H}^2 := \left\{ Z \text{ 可预测} : \|Z\|_{\mathcal{H}^2}^2 := \mathbb{E} \int_0^T |Z_s|^2 ds < \infty \right\}.$$

$\mathcal{S}^2$ 在上述范数下是Banach空间, $\mathcal{H}^2$ 是Hilbert空间。方程(1)应在 $\mathcal{S}^2 \times \mathcal{H}^2$ 中理解。

注. 对(1)求微分, 得到微分形式

$$-dY_t = f(t, Y_t, Z_t) dt - Z_t dB_t, \quad Y_T = \xi.$$

dY 前的负号只是记号约定: 它表明时间从 T 倒推。有些作者把它吸收进驱动函数, 写成 $\tilde{f} = -f$ 。




图 1: 非线性Feynman-Kac 公式背后的前向与倒向图像。扩散 $X^{t,x}$ 在时刻 t 从 x 出发, 正向演化到随机的终端值 X_T ; 接着终端收益 $\xi = g(X_T)$ 由BSDE 倒向传递, 生成 $Y_t = u(t, x)$ 。两个过程被 $[t, T]$ 上同一组布朗增量 dB_s 驱动: 前向方程通过扩散系数 σ , 倒向方程通过被积函数 Z 。适应性要求 Y_t 只能是截至 t 为止的历史的函数, 这正是 Z 不可或缺的原因。

2.2 两个热身例子

例2.2 ($f \equiv 0$: 伪装的线性Feynman-Kac). BSDE $(\xi, 0)$ 化为 $Y_t = \xi - \int_t^T Z_s dB_s$ 。取条件期望,

$$Y_t = \mathbb{E}[\xi \mid \mathcal{F}_t],$$

而 Z 是 $M_t = \mathbb{E}[\xi \mid \mathcal{F}_t]$ 的鞅表示中的被积函数。零驱动的BSDE 正是线性Feynman-Kac 公式。专门取 $\xi = g(X_T)$ 即可还原[SDE III, 定理 4.1]。

例2.3 (线性驱动与显式解). 对于 $f(t, y, z) = \alpha_t y + \beta_t \cdot z + \gamma_t$ (系数有界、适应), 定义折现因子与变测度因子

$$\Gamma_t := \exp\left(\int_0^t \alpha_s ds\right), \quad \frac{d\mathbb{P}^\beta}{d\mathbb{P}} \Big|_{\mathcal{F}_T} := \exp\left(\int_0^T \beta_s dB_s - \frac{1}{2} \int_0^T |\beta_s|^2 ds\right).$$

则

$$\Gamma_t Y_t = \mathbb{E}^\beta \left[\Gamma_T \xi + \int_t^T \Gamma_s \gamma_s ds \mid \mathcal{F}_t \right].$$

这个公式正是BSDE 版本的“常数变易法”, 后面证明比较定理时会用到。

3 存在性与唯一性

BSDE 理论的基石结果如下。

定理3.1 (Pardoux-Peng, 1990). 假设

- (i) $\xi \in L^2(\mathcal{F}_T)$;
- (ii) $(t, \omega) \mapsto f(t, \omega, 0, 0)$ 属于 $\mathcal{H}^2$;

(iii) f 对 (y, z) 一致Lipschitz, 即存在 $K \geq 0$ 使得

$$|f(t, \omega, y, z) - f(t, \omega, y', z')| \leq K(|y - y'| + |z - z'|)$$

对 $dt \otimes d\mathbb{P}$ -几乎所有 (t, ω) 成立。

则BSDE (1) 在 $\mathcal{S}^2 \times \mathcal{H}^2$ 中有唯一解 (Y, Z) 。

证明的精神类似于前向SDE 的Picard 迭代 ([SDE III, §2]) , 但引入一个新元素: 压缩发生在带指数权重的范数下, 权重恰好吸收Lipschitz 常数。

3.1 先验估计

引理3.2 (先验界). 若 $(Y, Z) \in \mathcal{S}^2 \times \mathcal{H}^2$ 解(1), 则对任意 $\beta > 2K + 2K^2$,

$$\mathbb{E} \int_0^T e^{\beta s} (|Y_s|^2 + |Z_s|^2) ds \leq C \left(\mathbb{E}[e^{\beta T} |\xi|^2] + \mathbb{E} \int_0^T e^{\beta s} |f(s, 0, 0)|^2 ds \right),$$

其中常数 C 仅依赖于 K 与 β 。

证明 (纲要). 对 $\varphi_t := e^{\beta t} |Y_t|^2$ 应用Itô 公式:

$$d\varphi_t = \beta e^{\beta t} |Y_t|^2 dt + 2e^{\beta t} Y_t dY_t + e^{\beta t} |Z_t|^2 dt.$$

代入 $dY_t = -f(t, Y_t, Z_t) dt + Z_t dB_t$ 并从 t 积到 T :

$$\begin{aligned} e^{\beta t} |Y_t|^2 + \int_t^T e^{\beta s} (\beta |Y_s|^2 + |Z_s|^2) ds &= e^{\beta T} |\xi|^2 + 2 \int_t^T e^{\beta s} Y_s f(s, Y_s, Z_s) ds \\ &\quad - 2 \int_t^T e^{\beta s} Y_s Z_s dB_s. \end{aligned}$$

取期望 (由 $(Y, Z) \in \mathcal{S}^2 \times \mathcal{H}^2$, 经局部化后Itô 积分的均值为零), 并分解

$$Y_s f(s, Y_s, Z_s) = Y_s f(s, 0, 0) + Y_s (f(s, Y_s, Z_s) - f(s, 0, 0)),$$

对第二部分用Lipschitz 条件, 配合基本不等式 $2|y||z| \leq \varepsilon |y|^2 + \varepsilon^{-1} |z|^2$, 选取适当小的 ε 和足够大的 β , 使得左侧的 $\beta |Y|^2$ 与 $|Z|^2$ 能吸收这些项。常数 $\beta > 2K + 2K^2$ 即可达成。□

直接推论即为唯一性。对同一个BSDE 的两个解 (Y, Z) 与 (Y', Z') , 将上述估计应用于二者之差: 终端条件与驱动差的自由项均为零, 于是 $Y - Y'$ 与 $Z - Z'$ 在相应范数下同时为零。由于 $Y - Y'$ 有连续版本, 结论可提升为所有时刻上的不可区分相等。

3.2 用压缩原理证存在性

定义映射 $\Phi : \mathcal{S}^2 \times \mathcal{H}^2 \rightarrow \mathcal{S}^2 \times \mathcal{H}^2$ 如下。给定 (y, z) , 令 $(Y, Z) := \Phi(y, z)$ 为以冻结驱动 $f^{y,z}(t, \omega) := f(t, \omega, y_t, z_t)$ 、终端条件 ξ 的BSDE 的解:

$$Y_t = \xi + \int_t^T f(s, y_s, z_s) ds - \int_t^T Z_s dB_s.$$

对于这个线性子问题 (右端不含 Y, Z), 解可以显式写出: 令

$$N_t := \mathbb{E} \left[\xi + \int_0^T f(s, y_s, z_s) ds \middle| \mathcal{F}_t \right].$$

则 N 为平方可积鞅；由布朗鞅表示， $N_t = N_0 + \int_0^t Z_s dB_s$ ，其中可预测的 $Z \in \mathcal{H}^2$ 唯一。令

$$Y_t := N_t - \int_0^t f(s, y_s, z_s) ds,$$

可直接验证 (Y, Z) 满足子问题且属于 $\mathcal{S}^2 \times \mathcal{H}^2$ 。

下面这个引理把先验界转化为对 Φ 的定量 Lipschitz 估计。

引理3.3 (差估计). 对 $(y, z), (y', z') \in \mathcal{S}^2 \times \mathcal{H}^2$ ，令 $(Y, Z) := \Phi(y, z)$ 、 $(Y', Z') := \Phi(y', z')$ 。对任意 $\beta \geq 2$,

$$\|(Y - Y', Z - Z')\|_\beta^2 \leq \frac{4K^2}{\beta} \|(y - y', z - z')\|_\beta^2,$$

其中 $\|(U, V)\|_\beta^2 := \mathbb{E} \int_0^T e^{\beta s} (|U_s|^2 + |V_s|^2) ds$ ， K 为 f 对 (y, z) 的 Lipschitz 常数。

证明. 记 $\Delta y := y - y'$ 、 $\Delta z := z - z'$ 、 $\Delta Y := Y - Y'$ 、 $\Delta Z := Z - Z'$ 、 $\Delta f_s := f(s, y_s, z_s) - f(s, y'_s, z'_s)$ 。两个冻结 BSDE 在 T 时刻完全相同 ($\Delta Y_T = 0$)，相减得

$$d\Delta Y_t = -\Delta f_t dt + \Delta Z_t dB_t.$$

对 $e^{\beta s} |\Delta Y_s|^2$ 在 $[0, T]$ 上应用 Itô 公式并取期望，利用 $\Delta Y_T = 0$:

$$\mathbb{E} |\Delta Y_0|^2 + \mathbb{E} \int_0^T e^{\beta s} (\beta |\Delta Y_s|^2 + |\Delta Z_s|^2) ds = 2 \mathbb{E} \int_0^T e^{\beta s} \Delta Y_s \Delta f_s ds.$$

由 Lipschitz 性， $|\Delta f_s| \leq K(|\Delta y_s| + |\Delta z_s|)$ 。对每个交叉项应用 $2ab \leq \frac{\beta}{4} a^2 + \frac{4}{\beta} b^2$:

$$2 \Delta Y_s \Delta f_s \leq \frac{\beta}{2} |\Delta Y_s|^2 + \frac{4K^2}{\beta} (|\Delta y_s|^2 + |\Delta z_s|^2).$$

丢掉非负项 $\mathbb{E} |\Delta Y_0|^2$ ，再把 $\frac{\beta}{2} |\Delta Y|^2$ 吸收到左侧，并用 $\beta \geq 2$ 将左侧控制为所需的加权范数，即得

$$\mathbb{E} \int_0^T e^{\beta s} (|\Delta Y_s|^2 + |\Delta Z_s|^2) ds \leq \frac{4K^2}{\beta} \mathbb{E} \int_0^T e^{\beta s} (|\Delta y_s|^2 + |\Delta z_s|^2) ds.$$

□

取任何 $\beta > 4K^2$ (例如 $\beta = 8K^2 + 2$) 即可使 Φ 在 $\|\cdot\|_\beta$ 下成为严格压缩，压缩比为 $\sqrt{4K^2/\beta} < 1$ 。严格地说， $\|\cdot\|_\beta$ 控制的是时间积分意义下的 L^2 大小，而不是 $\mathcal{S}^2$ 的上确界范数。因此，压缩原理先在对应的加权 L^2 适应过程空间中应用，得到唯一不动点。随后利用线性 BSDE 的表示、Doob 不等式与 BDG 不等式，可推出所得的 Y 具有连续版本且属于 $\mathcal{S}^2$ ，同时 $Z \in \mathcal{H}^2$ 。由构造知该不动点就是 BSDE (1) 的解。结合先前的唯一性推论，定理 3.1 证毕。□

注(为何用加权范数?)。未加权的 L^2 范数行不通：同一计算给出的压缩常数为 $4K^2 T$ ，只要 T 稍大就会 ≥ 1 。指数权 $e^{\beta s}$ 把时间重新标度，使得 Lipschitz 预算可以在局部花掉，而全局时域 T 不会进入估计。这个技巧 (即所谓“Bielecki 范数”) 是 Picard 型压缩在长时段上的标准解药，曾在 [SDE III, §2] 处理前向 SDE 时出现；这里它更不可缺，因为 BSDE 不能通过分段短步拼接求解：缩小 T 没有用，终端条件就在 T 上。

注(若 f 对 y 仅单调?)。Lipschitz 可被“对 y 单调+ 对 y 多项式增长、对 z 仍 Lipschitz” (Pardoux 1999) 取代，证明更精细但纲要相同。对 z 的二次增长 (Kobylanski 2000) 要求 ξ 有界，所需技巧完全不同 (指数变换)。

4 比较定理

BSDE 的一个标志性特征 (前向理论中没有对应物) 就是下列关于数据的单调性。

定理4.1 (比较定理). 设 (Y^1, Z^1) 、 (Y^2, Z^2) 分别解BSDE (ξ^1, f^1) 、 (ξ^2, f^2) , 两个驱动皆Lipschitz。假设

$$\xi^1 \leq \xi^2 \text{ a.s.}, \quad f^1(t, Y_t^1, Z_t^1) \leq f^2(t, Y_t^1, Z_t^1) \quad dt \otimes d\mathbb{P}\text{-a.e.}$$

则对任意 $t \in [0, T]$, 几乎处处有 $Y_t^1 \leq Y_t^2$ 。

证明 (纲要). 令 $\Delta Y := Y^2 - Y^1$ 、 $\Delta Z := Z^2 - Z^1$ 。两个BSDE 相减:

$$-d\Delta Y_t = [f^2(t, Y_t^2, Z_t^2) - f^1(t, Y_t^1, Z_t^1)] dt - \Delta Z_t dB_t.$$

对驱动函数之差作线性化:

$$f^2(t, Y_t^2, Z_t^2) - f^1(t, Y_t^1, Z_t^1) = \alpha_t \Delta Y_t + \beta_t \cdot \Delta Z_t + \gamma_t,$$

其中 α, β 有界 (由Lipschitz 性), $\gamma_t := f^2(t, Y_t^1, Z_t^1) - f^1(t, Y_t^1, Z_t^1) \geq 0$ (由假设)。所以 ΔY 解一个带非负源项的线性 BSDE。通过Girsanov 变测度 ([SDE III, §5])

$$\frac{d\mathbb{P}^\beta}{d\mathbb{P}} \Big|_{\mathcal{F}_T} = \exp \left(\int_0^T \beta_s dB_s - \frac{1}{2} \int_0^T |\beta_s|^2 ds \right),$$

把 $\beta \cdot \Delta Z$ 项吸收进新的布朗运动。利用§2.2 中线性驱动的显式公式:

$$\Delta Y_t = \mathbb{E}^{\mathbb{P}^\beta} \left[e^{\int_t^T \alpha_s ds} \Delta \xi + \int_t^T e^{\int_t^s \alpha_r dr} \gamma_s ds \mid \mathcal{F}_t \right].$$

被积函数是两个非负量之和 ($\Delta \xi \geq 0$ 、 $\gamma \geq 0$)，故 $\Delta Y_t \geq 0$ 。 $\square$

注(金融解释). 在期权定价模型中, Y_t 表示一份在到期日 T 支付 ξ 的合约在时刻 t 的价格, f 编码对冲成本(利率、红利、组合约束)。比较定理表明: 更高的收益或更便宜的对冲, 导致更高的价格。这是无套利的动态规划形式, 例如在模型不确定性下推导价格上界时, 它就是基础。

推论4.2 (严格比较). 在定理 4.1 的假设下, 若另外有

$$\mathbb{P}(\xi^1 < \xi^2) > 0 \quad \text{或} \quad f^1 < f^2 \text{ 在 } (Y^1, Z^1) \text{ 处于正 } dt \otimes d\mathbb{P}\text{-测度集上成立,}$$

则 $Y_0^1 < Y_0^2$ 。

证明. 在定理 4.1 的证明中得到的表达式

$$\Delta Y_0 = \mathbb{E}^{\mathbb{P}^\beta} \left[e^{\int_0^T \alpha_s ds} \Delta \xi + \int_0^T e^{\int_0^s \alpha_r dr} \gamma_s ds \right]$$

中, 被积函数非负; 在所述假设之下, 它又在一个正 $\mathbb{P}^\beta$ -测度集上严格为正 (由于 $\mathbb{P}^\beta$ 与 $\mathbb{P}$ 绝对连续, 这等同于正 $\mathbb{P}$ -测度), 所以 $\Delta Y_0 > 0$ 。 $\square$

4.1 g -期望与动态风险测度

比较定理使下面的构造得以合理定义。固定Lipschitz 驱动 $g : [0, T] \times \mathbb{R} \times \mathbb{R}^d \rightarrow \mathbb{R}$, 满足 $g(t, y, 0) = 0$; 对 $\xi \in L^2(\mathcal{F}_T)$, 记 (Y^ξ, Z^ξ) 为BSDE (ξ, g) 的唯一解。定义 g -期望及其条件版本:

$$\mathcal{E}_g[\xi] := Y_0^\xi, \quad \mathcal{E}_g[\xi \mid \mathcal{F}_t] := Y_t^\xi.$$

条件 $g(\cdot, \cdot, 0) = 0$ 保证 $\mathcal{E}_g[c] = c$ 对常数 c 成立。算子 $\mathcal{E}_g$ 一般对 ξ 非线性 (线性当且仅当 g 对 (y, z) 线性), 但保留了期望的结构性质:

(M) 单调性: $\xi^1 \leq \xi^2 \Rightarrow \mathcal{E}_g[\xi^1 \mid \mathcal{F}_t] \leq \mathcal{E}_g[\xi^2 \mid \mathcal{F}_t]$ (定理 4.1)。

(T) 时间相容性: 当 $t \leq s$ 时, $\mathcal{E}_g[\mathcal{E}_g[\xi | \mathcal{F}_s] | \mathcal{F}_t] = \mathcal{E}_g[\xi | \mathcal{F}_t]$ (BSDE 的流性质)。

(L) 局部性与零一律: 对 $A \in \mathcal{F}_t$, $\mathbf{1}_A \mathcal{E}_g[\xi | \mathcal{F}_t] = \mathcal{E}_g[\mathbf{1}_A \xi | \mathcal{F}_t]$ 。

若进一步假设驱动不依赖 y , 并且作为 z 的函数正齐次、次可加, 则 $\rho_t(\xi) := \mathcal{E}_g[-\xi | \mathcal{F}_t]$ 给出一个动态一致风险测度 (dynamic coherent risk measure, Artzner–Delbaen–Eber–Heath 意义下)。若驱动对 z 凸, 则得到动态凸风险测度。反过来, Coquet、Hu、Mémin 与 Peng 的表示定理刻画了哪些动态时间相容的非线性期望可以由 BSDE 产生。典型的支配条件常用次线性驱动 $g_\mu(z) = \mu|z|$ 表示, 这里的 g_μ 不是线性函数, 而是次线性函数。驱动的非线性可以编码对冲摩擦, 例如买卖价差、抵押品、资本费用, 也可以编码对模型或分布的 Knight 不确定性。

5 非线性 Feynman–Kac 公式

我们把场景特化到能与 PDE 接轨的 Markov 设定。

5.1 设定

固定 $(t, x) \in [0, T) \times \mathbb{R}^n$ 。考虑前向 SDE

$$dX_s^{t,x} = b(s, X_s^{t,x}) ds + \sigma(s, X_s^{t,x}) dB_s, \quad X_t^{t,x} = x, \quad s \in [t, T], \quad (2)$$

其中 $b: [0, T] \times \mathbb{R}^n \rightarrow \mathbb{R}^n$ 、 $\sigma: [0, T] \times \mathbb{R}^n \rightarrow \mathbb{R}^{n \times d}$ 满足 [SDE III, §2] 中的标准 Lipschitz 与线性增长假设。与之耦合的 BSDE 为

$$Y_s^{t,x} = g(X_T^{t,x}) + \int_s^T f(r, X_r^{t,x}, Y_r^{t,x}, Z_r^{t,x}) dr - \int_s^T Z_r^{t,x} dB_r, \quad (3)$$

其中 $g: \mathbb{R}^n \rightarrow \mathbb{R}$ 连续且多项式增长, $f: [0, T] \times \mathbb{R}^n \times \mathbb{R} \times \mathbb{R}^d \rightarrow \mathbb{R}$ 连续且对 (y, z) 一致 Lipschitz。由定理 3.1, BSDE (3) 有唯一解。

定义候选 PDE 解

$$u(t, x) := Y_t^{t,x}.$$

注意 $Y_t^{t,x}$ 是 $\mathcal{F}_t$ -可测的。另一方面, 从时刻 t 到 T 的方程只依赖初值 x 以及布朗增量 $(B_s - B_t)_{s \geq t}$, 而这些增量独立于 $\mathcal{F}_t$ 。由解的唯一性可知 $Y_t^{t,x}$ 既独立于 $\mathcal{F}_t$ 又 $\mathcal{F}_t$ -可测, 因此它实际上是关于 (t, x) 的确定性数值—— $u(t, x)$ 是一个数, 而不是随机变量。

回顾 X 的生成元:

$$\mathcal{L}\varphi(t, x) := b(t, x) \cdot \nabla \varphi(t, x) + \frac{1}{2} \text{tr}(\sigma \sigma^\top(t, x) \nabla^2 \varphi(t, x)).$$

定理 5.1 (非线性 Feynman–Kac).

(a) (验证部分) 若多项式增长的函数 $v \in C^{1,2}([0, T] \times \mathbb{R}^n)$ 解半线性抛物型问题

$$\partial_t v(t, x) + \mathcal{L}v(t, x) + f(t, x, v(t, x), \sigma^\top(t, x) \nabla v(t, x)) = 0, \quad (4)$$

终端条件为 $v(T, x) = g(x)$, 则对每个 (t, x) ,

$$Y_s^{t,x} = v(s, X_s^{t,x}), \quad Z_s^{t,x} = \sigma^\top(s, X_s^{t,x}) \nabla v(s, X_s^{t,x})$$

是 BSDE (3) 的唯一解。特别地, $u(t, x) = v(t, x)$ 。

(b) (表示部分) 反之, 若由 BSDE 定义的候选 $u(t, x) := Y_t^{t,x}$ 属于 $C^{1,2}$, 则 u 解 (4), 且终端条件为 g 。

证明（验证部分）。设 $v \in C^{1,2}$ 解(4)。对 $v(s, X_s^{t,x})$ 应用Itô 公式:

$$dv(s, X_s) = (\partial_s v + \mathcal{L}v)(s, X_s) ds + \nabla v(s, X_s)^\top \sigma(s, X_s) dB_s.$$

由PDE (4), 漂移项变为 $-f(s, X_s, v, \sigma^\top \nabla v)$, 故

$$-dv(s, X_s) = f(s, X_s, v(s, X_s), \sigma^\top(s, X_s) \nabla v(s, X_s)) ds - \sigma^\top(s, X_s) \nabla v(s, X_s) dB_s,$$

终端值为 $v(T, X_T) = g(X_T)$ 。这恰好是BSDE (3), 其中 $Y_s := v(s, X_s)$ 、 $Z_s := \sigma^\top(s, X_s) \nabla v(s, X_s)$ 。由定理 3.1 的唯一性, 这是唯一解。□

反向（表示）部分更微妙。若已知由BSDE 定义的 u 属于 $C^{1,2}$, 则可反向应用Itô 公式验证PDE。至于如何从系数假设推出 u 的这种经典正则性, 常见方法包括Malliavin 正则性、前向随机流的可微性, 以及一致椭圆情形下的抛物型正则性估计。可参考El Karoui、Peng、Quenez [2] 与Pardoux、Răşcanu [4] 的相关论述。

注(为什么是 $\sigma^\top \nabla u$ 而不是 ∇u ?)。前向SDE 通过 σ 驱动噪声。对 $v(s, X_s)$ 做Itô 公式产生 $(\nabla v)^\top \sigma dB$, 所以对 dB 的被积函数 (即 Z) 等于 $\sigma^\top \nabla v$ 。当 $\sigma = I_d$ ($\mathbb{R}^d$ 上无漂移的布朗噪声) 时, 这退化为熟悉的 $Z = \nabla u$ 。

注(Malliavin 观点)。若 ξ 与相关系数在Malliavin (Nualart) 意义下可微, 则解 (Y, Z) 亦可微, 且有

$$Z_t = D_t Y_t \quad dt \otimes d\mathbb{P}\text{-a.e.}, \quad (5)$$

其中 D_t 是Malliavin 导数 (Pardoux–Peng 1992; El Karoui–Peng–Quenez 1997)。配对 $(D_s Y_t, D_s Z_t)_{s \leq t}$ 自身满足对(1) 形式求导所得的线性BSDE, 这把数据的正则性反馈为解的正则性。在Markov 情形下, 链式法则加上切线流公式 $D_s X_t = \mathbf{1}_{s \leq t} \nabla_x X_t^{s, X_s} \sigma(s, X_s)$ 把(5) 化为

$$Z_t = \sigma^\top(t, X_t) \nabla u(t, X_t),$$

不需要事先假设 $u \in C^{1,2}$, 即可匹配定理 5.1(a)。Malliavin 路径可以作为证明正则性的工具之一: 它通常先给出 u 在 X 的分布支集上的Sobolev 正则性; 在 $\sigma \sigma^\top$ 一致椭圆等条件下, 还可以结合抛物型正则性估计升级到经典正则性。

5.2 线性与非线性的并列对照

线性Feynman–Kac ([SDE III])	非线性Feynman–Kac (本文)
PDE: $\partial_t u + \mathcal{L}u = 0, u(T, x) = g(x)$	PDE: $\partial_t u + \mathcal{L}u + f(t, x, u, \sigma^\top \nabla u) = 0, u(T, x) = g(x)$
概率端: 仅前向SDE $(X^{t,x})$	概率端: 前向SDE 加上 (Y, Z) 的BSDE
表示: $u(t, x) = \mathbb{E}[g(X_T^{t,x})]$	表示: $u(t, x) = Y_t^{t,x}$, 即BSDE 的初值
梯度 ∇u : 没有直接表示, 需Bismut–Elworthy 或Malliavin	梯度: $Z_t^{t,x} = \sigma^\top(t, x) \nabla u(t, x)$, 可从BSDE 直接读出
PDE 漂移不依赖 u	f 可以对 u 与 ∇u 有任何 (Lipschitz) 非线性依赖

右栏在 $f \equiv 0$ 时退化为左栏, 即§2.2 的热身例子。

5.3 一个范例: Fisher–KPP 型方程

考虑 $\mathbb{R}$ 上的半线性方程

$$\partial_t u + \frac{1}{2} \partial_{xx} u + u(1 - u) = 0, \quad u(T, x) = \mathbf{1}_{x > 0},$$

$b \equiv 0, \sigma \equiv 1$ 。对应的前向过程是布朗运动 $X_s = x + B_s - B_t$, BSDE 为

$$Y_s = \mathbf{1}_{x+B_T-B_t>0} + \int_s^T Y_r(1 - Y_r) dr - \int_s^T Z_r dB_r.$$

严格来说，这个例子不完全满足定理 5.1 中的光滑假设：终端条件 $\mathbf{1}_{x>0}$ 不连续，驱动 $y \mapsto y(1-y)$ 也不是全局Lipschitz。处理方法是先把终端条件平滑化，并把驱动在 $[0, 1]$ 之外作Lipschitz 截断，随后利用稳定性与比较定理取极限。由于常数解 $y \equiv 0$ 与 $y \equiv 1$ 分别给出下界和上界，比较定理保证解保持在 $[0, 1]$ 内，因此在解的实际取值范围上，截断后的驱动与原驱动一致。由此可得到 $u(t, x) = Y_t^{t, x}$ 的概率表示，并以概率方法重现Fisher-KPP 方程的最大值原理。

BSDE 路径也给出一个求 u 的Monte Carlo 算法，完全不接触网格：前向模拟 X ，再对 (Y, Z) 用离散化逐步倒推。这就是§6.2 中Deep BSDE 方法的入口。




图 2: Fisher-KPP BSDE 在 $[0, T] = [0, 1]$ 上的四条 Y 轨道，初始位置取 $x_0 \in \{-0.5, -0.2, +0.2, +0.5\}$ 。我们先在一个细密的 (t, x) 网格上用显式倒推求解PDE $\partial_t u + \frac{1}{2} \partial_{xx} u + u(1-u) = 0$ ，再抽样布朗路径 B_s ，绘出 $Y_s = u(s, B_s + x_0)$ 。所有轨道都停留在 $[0, 1]$ 内：常数 $y \equiv 0$ 与 $y \equiv 1$ 本身分别是终端条件 $\xi = 0$ 、 $\xi = 1$ 的BSDE 解，比较定理（定理 4.1）把每个解夹在它们之间。每条轨道的终端值实现了沿对应布朗路径的指示函数 $\mathbf{1}_{B_T + x_0 > 0}$ 。

6 应用

6.1 随机最优控制与HJB

考虑受控扩散

$$dX_s^\alpha = b(s, X_s^\alpha, \alpha_s) ds + \sigma(s, X_s^\alpha) dB_s,$$

控制 α 取值于紧的作用集 $A \subset \mathbb{R}^k$ ，且须适应。给定运行成本 ℓ 与终端成本 g ，定义值函数

$$V(t, x) := \inf_{\alpha} \mathbb{E} \left[\int_t^T \ell(s, X_s^\alpha, \alpha_s) ds + g(X_T^\alpha) \mid X_t^\alpha = x \right].$$

由动态规划原理， V 形式上满足Hamilton-Jacobi-Bellman 方程

$$\partial_t V(t, x) + \inf_{a \in A} \left\{ b(t, x, a) \cdot \nabla V + \frac{1}{2} \text{tr}(\sigma \sigma^\top \nabla^2 V) + \ell(t, x, a) \right\} = 0, \quad V(T, x) = g(x).$$

在 σ 不依赖 a 的情形，也就是漂移控制，HJB 方程可写成半线性形式。为了与(4) 对齐，可以选取一个参考扩散

$$d\bar{X}_s = b_0(s, \bar{X}_s) ds + \sigma(s, \bar{X}_s) dB_s,$$

其生成元记为 $\mathcal{L}^0$ 。若 σ 可逆，则对应的驱动可写为

$$f(t, x, y, z) = \inf_{a \in A} \left\{ (b(t, x, a) - b_0(t, x)) \cdot \sigma^{-\top}(t, x) z + \ell(t, x, a) \right\}.$$

若取 $b_0 \equiv 0$ ，就得到常见的简化公式。若 σ 不可逆，则需以 $Z = \sigma^\top \nabla V$ 为主要对象，并使用广义Hamilton量。对应的BSDE在适当条件下给出 V 的概率表示，并为最优反馈控制 $\alpha^*(s, X_s) \in \arg \min_a \{\dots\}$ 的可测选择提供自然表达。

当 σ 也依赖 a 时，问题通常不再是普通的半线性PDE，而是完全非线性PDE。此时需要二阶BSDE（2BSDE），相关理论可参考Soner、Touzi与Zhang。

6.2 Deep BSDE: 高维PDE的深度学习方

PDE (4) 在高空间维度 n 下是基于网格的求解器力所不及的：每轴 N 个点，存储量为 $\Theta(N^n)$ 。Han、Jentzen、E的Deep BSDE方法[3]把求解PDE重新表述为单一的全局随机优化问题。将时间离散为 $0 = t_0 < t_1 < \dots < t_M = T$ ， $\Delta t = T/M$ 。参数化：

- 初值由一个标量 $\theta_0 \in \mathbb{R}$ 表示（ $u(0, x_0)$ 的候选值）；
- 空间梯度 $z(t, x) := \sigma^\top(t, x) \nabla u(t, x)$ 由参数为 θ 的神经网络 $z^\theta(t, x)$ 给出。

从 x_0 出发做 X 的前向Euler-Maruyama离散，并沿时间递推

$$Y_{t_{k+1}}^\theta = Y_{t_k}^\theta - f(t_k, X_{t_k}, Y_{t_k}^\theta, z^\theta(t_k, X_{t_k})) \Delta t + z^\theta(t_k, X_{t_k}) \cdot \Delta B_k,$$

其中 $Y_0^\theta = \theta_0$ 。通过终端不匹配损失

$$\mathcal{J}(\theta) := \mathbb{E} \left[|g(X_T) - Y_T^\theta|^2 \right]$$

对 $\theta = (\theta_0, \theta_{\text{net}})$ 做随机梯度下降训练。在最优处， $\theta_0 \approx u(0, x_0)$ ， $z^\theta(\cdot, \cdot) \approx \sigma^\top \nabla u$ 。

其数学内容是一个变分刻画： $u(0, x_0)$ 是唯一这样的值，使得当 $Y_0 = u(0, x_0)$ 、 Z 为BSDE的解时，残差 $g(X_T) - Y_T$ 几乎处处为零。把“几乎处处”换成“ L^2 ”即得损失函数，把“BSDE解 Z ”换成“最佳神经网络逼近 z^θ ”即得算法。 L^2 损失与几乎处处相等之间的桥梁，正是BSDE唯一性引理的伪装形式。

在实践中，Deep BSDE方法曾在若干百维基准问题上表现出明显优势，例如HJB、含违约风险的Black-Scholes与Allen-Cahn方程。具体误差与运行时间高度依赖网络结构、训练预算、离散化步数和问题本身，因此它更适合被看作高维PDE的概率数值框架，而不是一个无条件的精度保证。

7 展望

本系列下一篇文章可以沿着下列四条线索之一展开。

前向-倒向耦合（FBSDE）。 若前向系数依赖 Y 或 Z ，便得到耦合的前向-倒向SDE：

$$\begin{aligned} dX_s &= b(s, X_s, Y_s, Z_s) ds + \sigma(s, X_s, Y_s, Z_s) dB_s, \\ -dY_s &= f(s, X_s, Y_s, Z_s) ds - Z_s dB_s, \quad Y_T = g(X_T). \end{aligned}$$

这是通过Pontryagin极大值原理表达完全耦合随机最优控制的自然语言。其存在性要求单调性条件（Ma-Yong），或短时间假设（Antonelli），或者在PDE端有经典解时使用四步法（Ma-Protter-Yong）。




图 3: Deep BSDE 方法的架构。前向链（灰色）是由抽样布朗增量 ΔB_k 驱动的 X 的 Euler-Maruyama 离散。倒向链（红色与蓝色）从可训练标量 θ_0 出发，依规则 $Y_{k+1}^\theta = Y_k^\theta - f(t_k, X_k, Y_k^\theta, z_k^\theta) \Delta t + z_k^\theta \cdot \Delta B_k$ 沿时间正向递推，其中每个 z_k^θ 是一个小神经网络，将 X_k 映射到 $\sigma^\top(t_k, X_k) \nabla u(t_k, X_k)$ 。用 SGD 对终端不匹配损失 $\mathcal{J}(\theta)$ 训练，把 θ_0 推向 $u(0, x_0)$ 。让这一切起作用的变分刻画，本质上就是定理 3.1 的唯一性部分。

平均场BSDE。 让驱动函数依赖边际分布 $\mathcal{L}(Y_s)$ ，便得到 McKean-Vlasov BSDE，这是平均场博弈的自然语言。对应的 PDE 定义在 $[0, T] \times \mathbb{R}^n \times \mathcal{P}_2(\mathbb{R}^n)$ 上，即所谓的主方程（master equation），并联系回 Lions 的 Wasserstein 微积分。

反射型BSDE 与美式期权。 反射型 BSDE (El Karoui-Kapoudjian-Pardoux-Peng-Quenez 1997) 为方程加上一个障碍过程 $L = (L_t)$ ：解是三元组 (Y, Z, K) ，其中 K 连续非减、 $K_0 = 0$ ， $Y_t \geq L_t$ a.s.，且

$$Y_t = \xi + \int_t^T f(s, Y_s, Z_s) ds + K_T - K_t - \int_t^T Z_s dB_s,$$

并满足 Skorokhod 条件 $\int_0^T (Y_t - L_t) dK_t = 0$ 。过程 K 把 Y 最少地向上推，且只在 Y 触及障碍时才推。对应的 PDE 是障碍问题

$$\min\{-\partial_t u - \mathcal{L}u - f(t, x, u, \sigma^\top \nabla u), u - L\} = 0, \quad u(T, x) = g(x).$$

若 f 不依赖 (Y, Z) ，反射型 BSDE 还给出普通最优停时问题的 Snell 包络表示：

$$Y_t = \operatorname{ess\,sup}_{\tau \in [t, T]} \mathbb{E} \left[\int_t^\tau f_s ds + L_\tau \mathbf{1}_{\tau < T} + \xi \mathbf{1}_{\tau = T} \middle| \mathcal{F}_t \right].$$

若 f 依赖 (Y, Z) ，上式中的普通条件期望应替换为相应的非线性 f -期望。

教科书级的应用是美式期权定价：行权价为 K 的看跌期权取 $L_t = (K - X_t)^+$ ，折现项 $f \equiv -ry$ ；提前行权边界正是接触集 $\{Y = L\}$ 。双障碍（Dynkin 博弈）与二阶变体沿用同一模板。

粗糙路径与粗糙BSDE。 若驱动噪声比布朗运动更粗糙（例如 Hurst 参数 $H < 1/2$ 的分数布朗运动），BSDE 背后的 Itô 微积分就失效了。Lyons 的粗糙路径理论与 Hairer 的正则性结构提供了替代工具；粗糙 BSDE 是活跃的研究领域，Diehl-Friz-Gassiat 的构造是标准参考。

参考文献

- [1] Pardoux, É., Peng, S. *Adapted solution of a backward stochastic differential equation*. Systems Control Lett. 14 (1990), 55–61.
- [2] El Karoui, N., Peng, S., Quenez, M. C. *Backward stochastic differential equations in finance*. Math. Finance 7 (1997), 1–71.
- [3] Han, J., Jentzen, A., E, W. *Solving high-dimensional partial differential equations using deep learning*. PNAS 115 (2018), 8505–8510.
- [4] Pardoux, É., Răşcanu, A. *Stochastic Differential Equations, Backward SDEs, Partial Differential Equations*. Springer, 2014.
- [5] Revuz, D., Yor, M. *Continuous Martingales and Brownian Motion*, 3rd ed., Springer, 1999.